Расчетно-графическая работа по дисциплине «Машинное обучение и большие данные»

Тема

Разработка Web-приложения (дашборда) для инференса (вывода) моделей ML и анализа данных.

Введение

Данная расчетно-графическая работа посвящена разработке интерактивного веб-приложения с использованием фреймворка Streamlit. Целью работы является демонстрация процесса анализа данных, обучения моделей машинного обучения и их использования для предсказания цен на алмазы. Проект включает в себя предобработку данных, обучение шести различных моделей регрессии, а также визуализацию данных и результатов предсказаний в удобном пользовательском интерфейсе.

1. Анализ данных и предобработка

Для выполнения работы был предоставлен набор данных `diamonds_processed.csv`, содержащий информацию о различных характеристиках алмазов и их ценах. Целевой переменной является `price` (цена алмаза).

1.1. Обзор данных

Набор данных содержит информацию о 20,000 записях (ограничено для ускорения обучения) и 10 признаках. Основные статистические характеристики

данных представлены в таблице ниже.

Feature	Type	Missing Values	Unique Values
carat	float64	0	252
cut	int64	0	5
color	int64	0	7
clarity	int64	0	8
depth	float64	0	184
table	float64	0	127
price	float64	0	11568
x	float64	0	295
y	float64	0	294
z	float64	0	209

1.2. Предобработка данных

В процессе предобработки данных были выполнены следующие шаги:

- **Масштабирование признаков:** Числовые признаки были масштабированы с использованием `StandardScaler` для приведения их к единому диапазону, что важно для корректной работы многих алгоритмов машинного обучения.
- **Разделение на обучающую и тестовую выборки:** Данные были разделены на обучающую (80%) и тестовую (20%) выборки для оценки производительности моделей.

2. Обучение моделей машинного обучения

Для решения задачи регрессии (предсказания цены алмазов) были обучены шесть различных моделей машинного обучения. Выбор моделей соответствует

требованиям задания и охватывает различные подходы: от классической линейной регрессии до глубоких нейронных сетей и ансамблевых методов.

2.1. Используемые модели

1. **ML1: Линейная регрессия (Linear Regression)**: Простая и интерпретируемая модель, устанавливающая линейную зависимость между признаками и целевой переменной.
2. **ML2: Градиентный бустинг (GradientBoostingRegressor)**: Мощный ансамблевый метод, строящий предсказания последовательно, корректируя ошибки предыдущих моделей.
3. **ML3: Гистограммный градиентный бустинг (HistGradientBoostingRegressor)**: Усовершенствованная версия градиентного бустинга, оптимизированная для больших наборов данных.
4. **ML4: Случайный лес (RandomForestRegressor)**: Ансамблевый метод, использующий множество деревьев решений и усредняющий их предсказания для повышения точности и устойчивости.
5. **ML5: Стэкинг (StackingRegressor)**: Мета-ансамблевый метод, который использует предсказания нескольких базовых моделей в качестве входных данных для финальной модели (мета-модели).
6. **ML6: Многослойный перцептрон (MLPRegressor)**: Полносвязная нейронная сеть, способная улавливать сложные нелинейные зависимости в данных.

2.2. Результаты обучения

Все модели были обучены на масштабированных данных. В качестве метрики качества использовался коэффициент детерминации R^2 (R-squared), который показывает долю дисперсии целевой переменной, объясняемую моделью. Чем ближе R^2 к 1, тем лучше модель.

Модель	Название	R^2 Score
ML1	Linear Regression	0.7498
ML2	Gradient Boosting	0.9305
ML3	HistGradientBoosting	0.9547
ML4	Random Forest	0.9526
ML5	Stacking Ensemble	0.9477
ML6	MLP Neural Network	0.9281

Как видно из таблицы, наилучшие результаты показали ансамблевые модели, в частности `HistGradientBoostingRegressor` и `RandomForestRegressor`, что ожидаемо для сложных задач регрессии.

3. Веб-приложение Streamlit

Разработано интерактивное веб-приложение с использованием фреймворка Streamlit, доступное по ссылке: https://8501-iceyoyfm1bc17c0cstuv4-b804a95f.us1.manus.computer. Приложение состоит из четырех основных страниц:

3.1. Developer Info (Информация о разработчике)

Эта страница содержит общую информацию о проекте и разработчике. Включает ФИО, номер группы, название университета, тему РГР и краткое описание целей проекта. Также перечислены основные технологии, использованные в разработке.

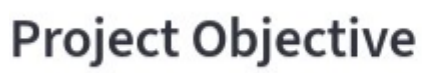

3.2. Dataset Info (Информация о наборе данных)

На этой странице представлен подробный обзор используемого набора данных. Включает общее количество записей и признаков, статистическое описание

данных (`df.describe()`), информацию о типах признаков, пропущенных значениях и количестве уникальных значений. Также отображаются ключевые метрики целевой переменной `price` (минимальная, средняя, максимальная цена) и краткое описание шагов предобработки.

	carat	cut	color	clarity	depth	table	price	x	y	z
count	53265	53265	53265	53265	53265	53265	53265	53265	53265	53265
mean	0.8	2.22	4.18	3.24	61.75	57.45	3952.83	5.74	5.75	3.55
std	0.47	1.26	2.05	1.76	1.43	2.23	3980.1	1.11	1.1	0.68
min	0.23	1	1	1	43	43	327	4	4	2.06
25%	0.4	1	2	2	61	56	967	4.73	4.74	2.92
50%	0.71	2	5	3	61.8	57	2440	5.71	5.72	3.53
75%	1.04	4	6	4	62.5	59	5356	6.54	6.54	4.04
max	3.01	5	7	8	79	95	18823	8.99	8.97	6.16

3.3. Data Visualization (Визуализация данных)

Страница визуализации данных демонстрирует ключевые распределения и зависимости в наборе данных с помощью четырех различных графиков:

1. **Распределение цен на алмазы (Price Distribution)**: Гистограмма, показывающая частоту различных ценовых диапазонов.
2. **Цена против первого признака (Price vs First Feature)**: Диаграмма рассеяния, иллюстрирующая зависимость цены от одного из признаков (например, `carat`).
3. **Box Plot цен (Price Box Plot)**: Ящичковая диаграмма, отображающая медиану, квартили и выбросы в распределении цен.
4. **Корреляционная матрица признаков (Feature Correlation)**: Тепловая карта, показывающая взаимосвязи между всеми числовыми признаками в наборе данных.

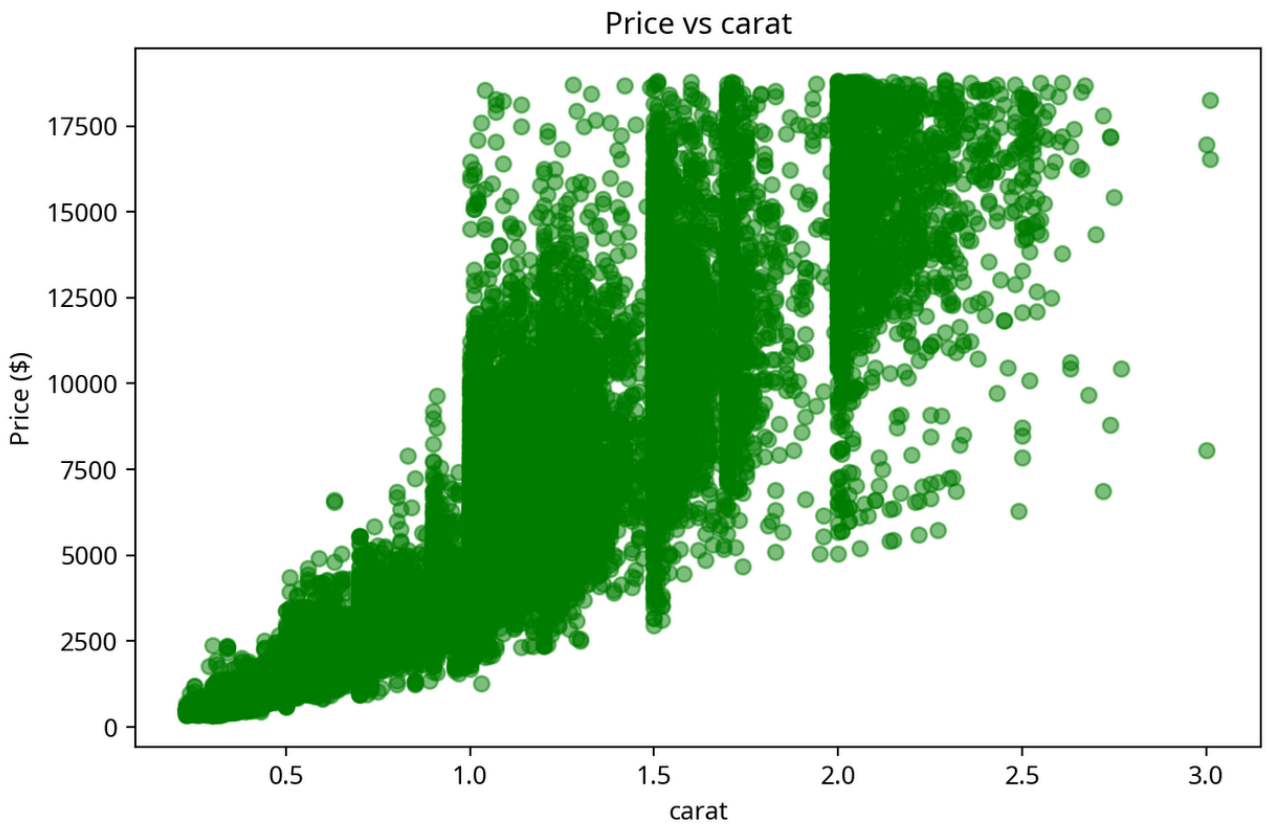

3.4. Model Prediction (Предсказание моделей)

На этой странице пользователи могут взаимодействовать с обученными моделями для получения предсказаний. Представлены R^2-метрики для каждой из шести моделей. Пользователь может выбрать один из двух методов ввода данных:

- **Ручной ввод (Manual Input)**: Ввод значений для каждого признака через интерактивные поля. После ввода модель делает предсказание цены.
- **Загрузка CSV (Upload CSV)**: Загрузка CSV-файла с данными для предсказания. Приложение обрабатывает файл, делает предсказания для каждой строки и позволяет скачать результаты в новом CSV-файле.

Заключение

В рамках данной расчетно-графической работы было успешно разработано и развернуто веб-приложение на Streamlit для анализа данных и предсказания

цен на алмазы. Были обучены и оценены шесть различных моделей машинного обучения, демонстрирующие высокую производительность в задаче регрессии. Приложение предоставляет удобный интерфейс для изучения данных, их визуализации и использования обученных моделей для получения предсказаний. Это подтверждает практическую применимость методов машинного обучения и фреймворка Streamlit для создания интерактивных аналитических инструментов.

Список источников

1. **GitHub Repository:** https://github.com/nikitabiba/NEW_ML_OmSTU
2. **Streamlit Documentation:** https://streamlit.io/
3. **Scikit-learn Documentation:** https://scikit-learn.org/